

Aula 08 – Detecção e reconhecimento de objetos

Prof. João Fernando Mari

joaofmari.github.io joaof.mari@ufv.br

Roteiro




- Localização, detecção e segmentação
- Família R-CNN
 - R-CNN
 - Fast R-CNN
 - Faster R-CNN
- Família YOLO

Localização, detecção e segmentação







Object Detection

Instance Segmentation





CAT





GRASS, CAT, TREE, SKY

No objects, just pixels

Single Object

DOG, DOG, CAT

DOG, DOG, CAT

Multiple Object

This image is CCO public domai

Stanford cs231n (2022): http://cs231n.stanford.edu/slides/2022/lecture 9 jiajun.pdf



R-CNN



R-CNN: Regions with CNN features

warped region



1. Input image



2. Extract region proposals (~2k)



4. Classify regions

tvmonitor? no.


aeroplane? no.

person? yes.

Ross Girshick, et al. "Rich feature hierarchies for accurate object detection and semantic segmentation.", 2014.

R-CNN





R-CNN




- R-CNN Region-based Convolutional Neural Network
- Varre a imagem buscando possíveis objetos
 - Selective Search
 - Gera ~2000 propostas de regiões
- Passa as propostas de regiões por uma CNN
 - Antes, redimensiona as regiões para o tamanho da camada de entrada da CNN.
- Baseado na saída da CNN:
 - Classifica a região com um classificador SVM
 - Aplica regressão linear para localizar o bounding-box do objeto.




FAST R-CNN





Ross Girshick. "Fast R-CNN.", 2015.








- A imagem de entrada passa por uma CNN
 - Um modelo pré-treinado da VGG-16 é usado para extração de características.
- No final da CNN é incluída uma camada chamada de Region of Interest Pooling Layer (Rol Pooling)
 - Rols obtidas a partir da imagem de entrada
- A saída da CNN é interpretada por uma camada completamente conectada.
- Na sequencia, o modelo bifurca em duas saídas:
 - Uma para a predição de classe via camada softmax
 - Outra com uma saída linear para o bounding-box.
- O processo é repetido múltiplas vezes para cada região de interesse em uma imagem.




FASTER R-CNN





Ren, et al. "Faster R-CNN: Towards Real-Time Object Detection with Region Proposal Networks.", 2016.





 $\underline{https://towardsdatascience.com/understanding-and-implementing-faster-r-cnn-a-step-by-step-guide-11acfff216b0}$



- Etapa 1: Rede de propostas de regiões (region proposal network)
 - A imagem toda passa por uma CNN pré-treinada (ResNet, VGG-16, ...)
 - A saída é um mapa de características
 - Cada ponto do mapa de características é tratado como uma âncora.
 - Para cada âncora, são geradas múltiplas caixas com tamanhos diferentes
 - Uma CNN com kernels 1x1 é usada para predizer a categoria e offset das caixas
 - Comparando as caixas com o ground-truth (durante o treinamento)
 - » Discriminadas caixas positivas (objetos) e negativas (fundo)
 - » Entropia cruzada binária com função de perda
 - Uma CNN com kernel 1x1 aprende os bounding-boxes dos objetos
 - » Regressão com função de perda L2 (distância Euclidiana)
 - As caixas são transformadas de acordo com os bounding-boxes
 - Propostas de região.



• Etapa 2:

- Uma CNN simples classifica as propostas de região em múltiplas classes
 - Entropia cruzada
 - Rol pooling é usado para redimensionar as propostas de região para o tamanho da entrada de rede.
- Outra rede usa regressão para alinhar os bounding-boxes
 - Função de perda L2
- A função de perda final combina entropia cruzada com L2




YOLO family



- YOLO You Only Look Once
- YOLO (2015)
- YOLOv2 (2017)
- YOLOv3 (2018)
- YOLOv4 (2020)
- YOLOv5 (2020)
- YOLOv6 (2022)
- YOLOv7 (2022)
- ...




- Etapa 1: Blocos residuais
 - Dividir a imagem em pequenas caixas organizadas em grade



https://www.exxactcorp.com/blog/Deep-Learning/YOLOv5-PyTorch-Tutorial




- Etapa 2: Regressão do bounding-box
 - Identifica os objetos dentro de um bounding-box
 - Após detectar um objeto, desenha um bounding-box ao seu redor
 - center point, height, width, and class




https://www.exxactcorp.com/blog/Deep-Learning/YOLOv5-PyTorch-Tutorial



- Etapa 3: Intersecção sobre União (IoU *Intersection over Union*)
 - Usado para calcular a acurácia do modelo








https://www.exxactcorp.com/blog/Deep-Learning/YOLOv5-PyTorch-Tutorial





https://www.section.io/engineering-education/introduction-to-yolo-algorithm-for-object-detection/



DATASETS

Datasets




- COCO DATASET
 - https://cocodataset.org/
 - Detecção de objetos
 - Segmentação
 - 330 K imagens
 - >200K imagens rotuladas
 - 1.5 milhões de instâncias de objetos
 - 80 classes de objetos
 - ...



Datasets



- PASCAL VOC 2012 DATASET
 - https://www.kaggle.com/datasets/gopalbhattrai/pascal-voc-2012-dataset
 - http://host.robots.ox.ac.uk/pascal/VOC/voc2012/




Datasets



- The Vector-LabPics dataset focus
 - https://www.cs.toronto.edu/chemselfies/







Materials

Vessels

Bibliografia



- Ross Girshick, et al. "Rich feature hierarchies for accurate object detection and semantic segmentation.", 2014.
 - https://arxiv.org/abs/1311.2524
- Ross Girshick. "Fast R-CNN.", 2015.
 - https://arxiv.org/abs/1504.08083
- Shaoqing Ren, et al. "Faster R-CNN: Towards Real-Time Object Detection with Region Proposal Networks.", 2016.
 - https://arxiv.org/abs/1506.01497
- Ross Girshick. Fast R-CNN. Facebook AI Research (FAIR). Work done at Microsoft Research.
 - https://dl.dropboxusercontent.com/s/vlyrkgd8nz8gy5l/fast-rcnn.pdf?dl=0
- Joseph Redmon, et al. "You Only Look Once: Unified, Real-Time Object Detection." 2015.
 - https://arxiv.org/abs/1506.02640
- CS231n: Deep Learning for Computer Vision. Stanford Spring 2022
 - http://cs231n.stanford.edu/

Bibliografia



- https://debuggercafe.com/a-simple-pipeline-to-train-pytorch-faster-rcnn-object-detection-model/
- https://pyimagesearch.com/2021/08/02/pytorch-object-detection-with-pre-trained-networks/
- https://machinelearningmastery.com/object-recognition-with-deep-learning/
- https://www.jeremyjordan.me/evaluating-image-segmentation-models/
- https://towardsdatascience.com/r-cnn-fast-r-cnn-faster-r-cnn-yolo-object-detection-algorithms-36d53571365e
- https://www.upgrad.com/blog/ultimate-guide-to-object-detection-using-deep-learning/
- https://towardsdatascience.com/deep-learning-for-object-detection-a-comprehensive-review-73930816d8d9
- https://pytorch.org/tutorials/intermediate/torchvision_tutorial.html
- https://pyimagesearch.com/2021/08/02/pytorch-object-detection-with-pre-trained-networks/
- https://github.com/chenyuntc/simple-faster-rcnn-pytorch
- https://blog.paperspace.com/faster-r-cnn-explained-object-detection/
- https://deepsense.ai/region-of-interest-pooling-explained/
- https://medium.com/codex/implementing-r-cnn-object-detection-on-voc2012-with-pytorch-b05d3c623afe
- https://towardsdatascience.com/understanding-and-implementing-faster-r-cnn-a-step-by-step-guide-11acfff216b0

Bibliografia



- https://www.exxactcorp.com/blog/Deep-Learning/YOLOv5-PyTorch-Tutorial
- https://www.section.io/engineering-education/introduction-to-yolo-algorithm-for-object-detection
- https://curiousily.com/posts/object-detection-on-custom-dataset-with-yolo-v5-using-pytorch-and-python/
- https://pyimagesearch.com/2022/04/04/introduction-to-the-yolo-family/
- https://towardsdatascience.com/yolov7-a-deep-dive-into-the-current-state-of-the-art-for-object-detection-ce3ffedeeaeb
- https://blog.paperspace.com/how-to-implement-a-yolo-object-detector-in-pytorch/
- https://www.section.io/engineering-education/object-detection-with-yolov5-and-pytorch/
- https://pytorch.org/hub/ultralytics_yolov5/



FIM